



**Université d'Alger 1 – Benyoucef
Benkhedda
Faculté des sciences
Département Informatique**



Rapport de Projet de TP

**Module : Entrepôt De Données
Enseignante : Mme Menai
Master 1 : Ingénierie des système
informatique intelligent**

**Sujet : la Mise en œuvre d'un système d'aide à
la décision pour l'Analyse d'évolution et
l'impact des ventes de colorants naturelles
dans l'industrie agroalimentaire**

**Réaliser par :
Benzineh Mohamed Salem G04
Ressam Chanez G04**

Année universitaire : 2024/2025




Table de matières

Introduction :	2
Chapitre 1 : Analyse des besoins et Modélisation Multidimensionnelle	6
1. Introduction :	6
2. Présentation de thème :	6
3. Création du Schéma en Étoile :	7
4. Conclusion :	10
Chapitre 2 : Intégration des Données (Processus ETL) :	11
1. Introduction :	11
2. Présentation Générale :	11
5. Préparation de la source de données	12
6. Création de l'entrepôt de données :	20
7. Création de la table de faits :	26
8. Conclusion :	32
Chapitre 3 : Création de cube OLAP	33
1. Introduction :	33
2. Data Mart :	33
3. Définition de Data Mart :	34
4. Création du Cube OLAP :	35
5. Conclusion	45
Chapitre 4 : Analyse et Visualisation des Résultats	46
1. Introduction :	46
2. Connexion de Power BI à la Base de Données MySQL "EntrepotDeDonnees"	46
3. Création des visualisations :	49
4. Conclusion :	58
Conclusion générale	59

Introduction :

Dans le cadre de ce projet, nous visons à concevoir un système d'aide à la décision destiné à analyser l'évolution et l'impact des ventes de colorants naturels dans l'industrie agroalimentaire. L'analyse repose sur des indicateurs clés tels que la quantité de colorant utilisée, le montant des ventes, et des scores d'impact sanitaire et environnemental, permettant ainsi de mieux comprendre les tendances de consommation et les performances environnementales.

L'objectif principal est de structurer et transformer les données disponibles (issues de fichiers simulés) en un entrepôt de données optimisé pour des analyses multidimensionnelles. Cela comprend les étapes de modélisation, intégration, et exploitation des données à travers un processus ETL (Extraction, Transformation et Chargement) en utilisant l'outil Talend Open Studio, avec un stockage dans **SQL** et une exploitation via **Power BI** ou un cube OLAP.(chanez)

Le projet se divise en plusieurs étapes principales :

- Une analyse des besoins, permettant d'identifier les faits à mesurer (volumes, ventes, scores d'impact) et les dimensions pertinentes (produits, colorants, fournisseurs, origine, temps).
- Une modélisation multidimensionnelle basée sur un schéma en étoile, structurant les données autour d'une table des faits Faits_Ventes_Colorants et de plusieurs dimensions comme Dim_Produit, Dim_Colorant, Dim_Fournisseur, etc.
- Une intégration des données via un processus ETL dans Talend, permettant d'extraire les données sources, de les transformer (calcul du montant de vente, conversion des scores en pourcentage, découpage des dates...) et de les charger dans la base datawarehouse.
- Une analyse finale OLAP, à travers un cube Mondrian ou des visualisations interactives sous Power BI, permettant d'explorer les ventes selon l'origine, le type de colorant, le fournisseur ou la période, tout en tenant compte de leur impact environnemental ou sanitaire.

Ce rapport documente chaque étape du processus, depuis la définition du sujet jusqu'à la mise en œuvre technique et à l'obtention des résultats analytiques finaux. Il met en évidence les choix technologiques et fonctionnels effectués afin d'aboutir à une solution cohérente, fiable et adaptée aux enjeux de traçabilité, durabilité et performance commerciale dans le domaine des colorants naturels.

Chapitre 1 : Analyse des besoins et Modélisation Multidimensionnelle

1. Introduction :

Ce chapitre se concentre sur l'identification des besoins analytiques et la construction du modèle multidimensionnel adapté à l'étude de l'évolution et de l'impact des ventes de colorants naturels dans l'industrie agroalimentaire.

Dans un premier temps, nous définissons les faits à analyser, ainsi que les mesures clés permettant d'évaluer les performances commerciales, sanitaires et environnementales liées à l'usage des colorants. Ensuite, nous identifions les dimensions descriptives, telles que le produit agroalimentaire, le type de colorant, son origine, son fournisseur, ainsi que la date de vente. Enfin, nous proposons un modèle en étoile structurant les relations entre la table de faits et les dimensions.

Cette étape constitue la base du système décisionnel, en organisant les données de manière optimale pour les futures analyses OLAP.

2. Présentation de thème :

Les colorants alimentaires jouent un rôle essentiel dans l'apparence et l'attractivité des produits agroalimentaires. Historiquement, l'industrie a largement eu recours aux **colorants synthétiques**, souvent critiqués pour leurs **effets sanitaires potentiels** et leur **impact environnemental**. Depuis quelques années, la tendance s'oriente progressivement vers l'utilisation de **colorants naturels**, issus de sources végétales (curcuma, betterave, spiruline, hibiscus, etc.), jugés plus sains, plus durables, et plus acceptés par les consommateurs.

Objectif du projet :

Ce projet vise à concevoir un **système d'aide à la décision** permettant d'**analyser l'évolution des ventes de colorants naturels** et d'**évaluer leur impact à la fois sur la santé et l'environnement**, tout en prenant en compte divers facteurs contextuels comme :

- le **type de produit alimentaire** dans lequel le colorant est utilisé,
- son **origine biologique ou conventionnelle**,
- le **fournisseur**, son **pays** et sa **certification** (BIO, ISO 22000, etc.),
- les **tendances temporelles** (par mois, trimestre, année).

Problématique abordée :

Comment l'industrie agroalimentaire évolue-t-elle vers des colorants naturels, et quels en sont les **impacts commerciaux, sanitaires et environnementaux** ?

Ce projet s'intéresse à :

- L'**adoption croissante des colorants naturels** par les industriels
- La **traçabilité des sources** et la qualité des fournisseurs

- L'évaluation de l'**impact écologique et sanitaire** de ces colorants
- La **préférence des consommateurs** selon les produits et certifications

Nature des données étudiées :

Les données utilisées dans ce projet ont été **simulées de manière réaliste** et organisées dans une architecture en étoile. Elles contiennent :

- des **mesures** : quantité vendue, montant, score santé, score environnement
- des **dimensions descriptives** : colorant, produit, origine, fournisseur, temps

Chaque ligne correspond à une vente individuelle de colorant, enrichie par les informations nécessaires à l'analyse multidimensionnelle.

Démarche mise en œuvre :

1. **Modélisation multidimensionnelle** (schéma en étoile)
2. **Processus ETL** avec Talend Open Studio
3. **Stockage des données** dans un entrepôt (PostgreSQL ou CSV)
4. **Exploration OLAP et visualisations interactives** avec Power BI

Intérêt et finalité du projet :

- Fournir un **outil d'aide à la décision** pour les industriels, les producteurs bio, ou les distributeurs alimentaires
- Mieux comprendre les **facteurs qui influencent le choix des colorants**
- Orienter vers des pratiques **plus durables et responsables**
- Mettre en avant l'importance de la **qualité des fournisseurs** et de la **traçabilité**

Résultats attendus :

Une base de données bien structurée, conforme au modèle décisionnel
Des **analyses visuelles claires** montrant :

- la montée des colorants naturels
- les produits et périodes les plus concernés
- les fournisseurs les plus durables
- Des **indicateurs clés** sur la santé, l'environnement, et les ventes

Identification des Faits :

➤ **Table des faits** : Popularité_anime

❖ **Les mesures clés (quantifiables) :**

- **Nombre de vues** : Mesure le nombre de vues par anime. Pertinent pour analyser la popularité globale.

- **Nombre d'évaluations** : Mesure le nombre total d'évaluations faites par les utilisateurs. Indique l'engagement ou l'intérêt des fans.

Identification des Dimensions :

Table des faits : Faits_Ventes_Colorants

Mesures clés (quantifiables) :

- **Quantité (kg)** : Masse totale du colorant utilisé dans une vente.
- **Montant de la vente (€)** : Chiffre d'affaires généré par la vente.
- **Score Santé (%)** : Indice représentant l'impact sanitaire estimé.
- **Score Environnement (%)** : Indice représentant l'impact environnemental.

Identification des dimensions associées à la table des faits :

Dimension Produit :

- id_produit (Clé primaire)
- nom_produit
- catégorie (ex : Laitier, Boisson, Confiserie)

Dimension Colorant :

- id_colorant (Clé primaire)
- nom_colorant
- type_colorant (Naturel ou Synthétique)
- code_E (ex : E100, E162)
- prix_unitaire (€)

Dimension Origine :

- id_origine (Clé primaire)
- source (Plante, Algue, etc.)
- nature (Biologique ou Conventionnelle)

Dimension Fournisseur :

- id_fournisseur (Clé primaire)
- nom_fournisseur
- pays
- certification (Bio, ISO 22000, etc.)

Dimension Temps :

- id_temps (Clé primaire)
- jour
- mois
- trimestre
- année

3. Création du Schéma en Étoile :

Le modèle multidimensionnel en étoile présenté ci-dessous (**Figure 1**) est conçu pour analyser l'impact commercial, sanitaire et environnemental des colorants naturels. Il repose sur une table des faits principale nommée *Faits_Ventes_Colorants*, qui regroupe les mesures clés de l'analyse : quantité, montant de vente, score santé et score environnement.

Cette table est reliée à plusieurs dimensions descriptives, telles que *Produit*, *Colorant*, *Fournisseur*, *Origine*, et *Temps*. Ces dimensions apportent un contexte riche : les caractéristiques du colorant utilisé, sa provenance, l'identité et les certifications du fournisseur, le produit agroalimentaire concerné, ainsi que des informations temporelles détaillées.

Ce modèle permet ainsi de réaliser des analyses croisées, comme :

- L'évolution des ventes de colorants naturels par **type de produit**
- L'analyse des **scores environnementaux moyens** par fournisseur
- L'identification des **origines les plus durables**
- Le suivi des **performances par trimestre ou année**




Figure 1: Modèle en étoile

Définition des Métadonnées :

Table des Faits : Faits_Ventes_Colorants

Attribut	Type	Format	Description
id_vente	INT	Clé primaire	Identifiant unique de la vente
id_temps	INT	Clé étrangère	Lien vers la date de la vente
id_produit	INT	Clé étrangère	Lien vers le produit concerné
id_colorant	INT	Clé étrangère	Lien vers le colorant utilisé
id_origine	INT	Clé étrangère	Lien vers l'origine du colorant
id_fournisseur	INT	Clé étrangère	Lien vers le fournisseur
quantite_kg	FLOAT	Nombre décimal (xx.xx)	Quantité de colorant vendue en kilogrammes
montant_vente	FLOAT	Nombre décimal (xx.xx)	Montant total de la vente en euros
score_sante	FLOAT	Pourcentage (0–100)	Score représentant l'impact sanitaire
score_env	FLOAT	Pourcentage (0–100)	Score représentant l'impact environnemental

Tables de Dimensions :

Table Dim_Produit

Attribut	Type	Format	Description
id_produit	INT	Clé primaire	Identifiant unique du produit alimentaire
nom_produit	STRING	Texte long	Nom du produit (ex. Boisson végétale)
catégorie	STRING	Texte court	Catégorie du produit (ex. Laitier, Confiserie)

Table Dim_Colorant

Attribut	Type	Format	Description
id_colorant	INT	Clé primaire	Identifiant unique du colorant
nom_colorant	STRING	Texte long	Nom du colorant (ex. Curcuma)
type_colorant	STRING	Texte court	Type : 'Naturel' ou 'Synthétique'
code_E	STRING	Code court	Code réglementaire du colorant (ex. E100)
prix_unitaire	FLOAT	Nombre décimal	Prix unitaire en €/kg

Table Dim_Origine

Attribut	Type	Format	Description
id_origine	INT	Clé primaire	Identifiant unique de l'origine
source	STRING	Texte court	Source : Plante, Algue, Épice...
nature	STRING	Texte court	Nature : 'Biologique' ou 'Conventionnelle'

Table Dim_Fournisseur

Attribut	Type	Format	Description
id_fournisseur	INT	Clé primaire	Identifiant unique du fournisseur
nom_fournisseur	STRING	Texte long	Nom du fournisseur
pays	STRING	Texte court	Pays du fournisseur
certification	STRING	Texte court	Certification : BIO, ISO 22000, etc.

Table Dim_Temps

Attribut	Type	Format	Description
id_temps	INT	Clé primaire	Identifiant unique de la date
jour	INT	1–31	Jour du mois
mois	INT	1–12	Mois de l'année
trimestre	STRING	T1 à T4	Trimestre de l'année
annee	INT	Format YYYY	Année de la vente

4. Conclusion :

Ce chapitre est fondamental dans le cadre du processus ETL, car il permet de **structurer clairement les données** en définissant les **tables de faits et de dimensions**. Cette structuration en schéma en étoile facilite :

- l'**extraction ciblée** des données utiles,
- leur **transformation cohérente** avec les besoins d'analyse,
- et leur **chargement propre** dans un entrepôt de données décisionnel.

En résumé, cette modélisation multidimensionnelle prépare une base solide pour des **analyses OLAP efficaces** et des **visualisations exploitables** sur les ventes, les impacts environnementaux/sanitaires et l'évolution temporelle de l'usage des colorants naturels.

Chapitre 2 : Intégration des Données (Processus ETL) :

1. Introduction :

Dans cette phase, nous utilisons **Talend Open Studio for Data Integration** pour réaliser un **processus ETL** (Extraction, Transformation, Chargement), adapté à notre projet portant sur l'analyse de **l'évolution et de l'impact des ventes de colorants naturels dans l'industrie agroalimentaire**.

L'objectif de cette étape est de **structurer, nettoyer et enrichir les données initiales**, issues de fichiers CSV simulés, afin de les intégrer dans un **entrepôt de données (Data Warehouse)** optimisé pour les analyses OLAP.

Les étapes principales :

1. Extraction (E) : Importer les données brutes depuis la source (fichier csv).
2. Transformation (T) : Appliquer des transformations pour préparer les dimensions et la table de faits (nettoyage, génération d'IDs, etc.).
3. Chargement (L) : Charger les données transformées dans la base cible (entrepôt de données).

2. Présentation Générale :

Outils et composants utilisés dans Talend

Talend Open Studio for Data Integration est un outil puissant d'intégration de données qui permet de créer visuellement des flux **ETL** (Extraction, Transformation, Chargement) à l'aide d'une interface **glisser-déposer** intuitive.

Dans le cadre de ce projet, plusieurs composants clés ont été utilisés pour construire les différents flux de traitement, chacun jouant un rôle spécifique dans le pipeline de données :

➤ tFileInputDelimited

Ce composant permet de **lire les données brutes** à partir de fichiers CSV représentant les dimensions (Dim_Colorant, Dim_Produit, etc.) ainsi que la table des faits (Faits_Ventes_Colorants).

Il est utilisé en **début de flux** pour extraire les données sources.

➤ tMap

Composant central du processus ETL, tMap permet de :
effectuer les **jointures** entre les sources,

transformer les données (ex. : calcul de $\text{montant_vente} = \text{quantite_kg} \times \text{prix_unitaire}$),
dériver de nouvelles colonnes (ex. : Trimestre, Score_Santé (%)),

filtrer ou supprimer des colonnes non pertinentes.

Il joue un rôle clé dans la **normalisation, l'enrichissement** et la **préparation des données** avant leur chargement.

➤ tDBOutput (ex: tPostgresqlOutput ou tMySQLOutput)

Ce composant permet de **charger les données transformées** dans une **base de données relationnelle**, ici un **entrepôt de données PostgreSQL** (ou MySQL selon le cas).

Chaque dimension et la table de faits y sont insérées selon le **modèle en étoile** défini.

Ces composants, combinés dans un flux logique, assurent un **traitement automatisé**, reproductible et fiable des données, de l'extraction initiale à l'insertion dans l'entrepôt de données prêt pour l'analyse OLA

• Présentation collaborative des données

Avant même de commencer l'intégration dans Talend, **nous avons pris le temps, avec mon binôme, d'analyser la structure de nos données.** Très vite, nous nous sommes mis d'accord sur l'idée qu'une modélisation propre devait s'appuyer sur un **fichier bien organisé**, cohérent avec une architecture en étoile. Nous avons généré nous-mêmes les jeux de données, en nous assurant qu'ils soient à la fois **réalistes et exploitables dans un contexte décisionnel.**

Nous avons volontairement conçu une **table des faits contenant exactement 100 ventes** pour disposer d'un jeu d'exemples suffisamment riche, tout en gardant des dimensions plus compactes (entre **30 et 65 lignes**), ce qui permet d'éviter les redondances. L'objectif était de simuler un environnement professionnel où **plusieurs ventes partagent des attributs communs** (même produit, même colorant, même date, etc.), tout en conservant **la variété nécessaire** pour permettre des analyses croisées.

Nous avons fait en sorte que chaque dimension décrive **uniquement les entités de référence** (produits, colorants, fournisseurs, etc.), tandis que la table des faits contient les mesures concrètes liées aux ventes. Ce découpage s'est avéré très utile dans Talend pour réaliser les jointures de manière claire, et dans Power BI pour analyser les tendances de fond.

Organisation des données

Les données initiales sont stockées dans un **fichier CSV**, contenant un total de **100 ventes de colorants** dans le secteur agroalimentaire. Ces données sont réparties en **tables distinctes** représentant la **table des faits** ainsi que les **dimensions** du modèle décisionnel.

Les colonnes sont organisées autour des informations suivantes :

- **Nom du colorant, type** (naturel ou synthétique), **code E, prix unitaire**
- **Produit alimentaire** concerné et sa **catégorie** (ex. Laitier, Boisson...)
- **Origine** du colorant (source végétale, épice, algue...), et sa **nature** (biologique ou conventionnelle)
- **Fournisseur, pays, et certification** (BIO, ISO...)
- **Date de vente**, décomposée en **jour, mois, trimestre, année**
- **Mesures de la table des faits** : **quantité vendue (kg), montant de la vente (€), score d'impact sanitaire et environnemental**

Le fichier est structuré pour permettre une **intégration fluide dans Talend** et une **modélisation en étoile**, facilitant les **analyses multidimensionnelles dans Power BI** ou via un **cube OLAP**.

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S									
1	id_vente	id_temps	id_produit	id_colorant	id_origine	id_Fournisseur	quantite_kg	score_sante	score_env	montant_vente	Date	trimestre	nom_produit	cat	g	orie	nom_colorant	type_colorant	code	E.prix	unitaire	source	nature	nom_Fournisseur	Pays	Cert		
2	1,5	41	60	8	34	63	33,0	0,7	0,0000000000000001	715,0	2023-01-05	T1	CV@rv@ales bio	Boisson	Betterave	Naturel	E140,11.29	Plante	Biologique	PureNature	France	ISO 22000						
3	2,74	13	19	63	38	14	48	10,0	10,0	154,21	2023-03-15	T1	Boisson	vi@gv@tale	Boulangerie	Spiruline	Naturel	E140,10.65	Vâpice	Conventionnelle	ColorBio	Inde	Bio					
4	3,87	22	41	73	97	81	39	3,0	67,0	790,3	2023-03-28	T1	CV@rv@ales bio	Boulangerie	Hibiscus	Synth	@tique	E100,9.71	Algue	Conventionnelle	BioColorant	Brv@sil	Bio					
5	4,26	85	99	70	49	53	35	56	9999999999999999	2,0	120,04	2023-01-26	T1	Pv@tisserie	artisanale	Laitier	Paprika	Synth	@tique	E162,2.25	Lv@gume	Conventionnelle	GreenExtract	Inde	Bio			
6	5,76	93	81	62	54	56	19	99	0,48	0,635	51	2023-03-17	T1	Bonbon	gv@liliv@	Confiserie	Paprika	Naturel	E160c,11.31	Fleur	Conventionnelle	ColorBio	Maroc	Bio				
7	6,14	30	50	43	24	91	51	90	48	0,840	98	2023-01-14	T1	CV@rv@ales bio	Confiserie	Paprika	Synth	@tique	E160c,9.19	Algue	Biologique	NatFood	Brv@sil	ISO 22000				
8	7,83	22	83	93	20	71	41	25	0,74	0,154	96	2023-03-24	T1	CV@rv@ales bio	Boulangerie	Curcuma	Synth	@tique	E162,2.17	Plante	Conventionnelle	ColorBio	Inde	ISO 22000				
9	8,57	42	11	89	1,23	01	16	0,52	0,216	29	2023-02-26	T1	Bonbon	gv@liliv@	Boulangerie	Spiruline	Synth	@tique	E140,9.4	Algue	Biologique	ColorBio	Maroc	Non certifi				
10	9	10	20	67	61	46	58	82	72	0,44	0,179	99	2023-01-10	T1	Yaourt	aux fruits	Petit-dv@jeuner	Betterave	Synth	@tique	E163,3.06	Lv@gume	Conventionnelle	ColorBio	Maroc	ISO 22000		
11	10	100	88	44	36	89	17	73	86	0,80	0,120	39	2023-04-10	T2	Pv@tisserie	artisanale	Confiserie	Curcuma	Naturel	E140,6.79	Vâpice	Biologique	PureNature	Maroc	ISO 22000			
12	11	71	77	57	100	44	72	52	4,0	91,0	627	3	2023-03-12	T1	Boisson	vi@gv@tale	Petit-dv@jeuner	Betterave	Naturel	E160c,8.65	Fleur	Conventionnelle	ColorBio	France	ISO 22000			
13	12	13	56	45	23	7	29	08	40	0,23	0,275	39	2023-01-13	T1	Pv@tisserie	artisanale	Laitier	Betterave	Naturel	E140,9.47	Plante	Conventionnelle	ColorBio	Maroc	ISO 22000			
14	13	55	40	75	59	17	73	44	0,70	0,185	46	2023-02-24	T1	Boisson	vi@gv@tale	Petit-dv@jeuner	Spiruline	Naturel	E100,10.46	Vâpice	Conventionnelle	ColorBio	France	Non certifi				
15	14	22	20	51	26	58	37	54	38	0,85	0,251	52	2023-01-22	T1	Yaourt	aux fruits	Petit-dv@jeuner	Curcuma	Synth	@tique	E140,6.7	Plante	Conventionnelle	NatFood	Allemagne	Bio		
16	15	54	32	3	60	31	80	67	55	0,0000000000000001	19,0	498,54	2023-02-23	T1	CV@rv@ales bio	Laitier	Betterave	Synth	@tique	E162,6.18	Algue	Conventionnelle	PureNature	Allemagne	ISO 22000			
17	16	52	1,3	42	37	83	93	40	0,17	0,518	69	2023-02-21	T1	Pv@tisserie	artisanale	Boisson	Betterave	Synth	@tique	E162,6.18	Vâpice	Conventionnelle	BioColorant	France	Non certifi			
18	17	79	10	44	55	18	16	52	98	0,11	0,112	17	2023-03-20	T1	Pv@tisserie	artisanale	Laitier	Curcuma	Naturel	E140,6.79	Plante	Conventionnelle	GreenExtract	Allemagne	Non certifi			
19	18	22	9	17	65	45	64	75	66	0,65	0,389	15	2023-01-22	T1	CV@rv@ales bio	Confiserie	Hibiscus	Naturel	E160c,6.01	Vâpice	Biologique	GreenExtract	Inde	Bio				
20	19	31	8	67	12	84	64	62	76	0,75	0,197	74	2023-01-31	T1	Bonbon	gv@liliv@	Laitier	Betterave	Synth	@tique	E163,3.06	Fleur	Biologique	NatFood	Maroc	Bio		
21	20	27	8	16	68	22	62	63	11,0	50,0	427,76	2023-01-27	T1	Bonbon	gv@liliv@	Laitier	Paprika	Naturel	E140,6.83	Vâpice	Biologique	PureNature	Inde	Non certifi				
22	21	57	21	77	89	56	59	78	83	0,71	0,696	44	2023-02-26	T1	Pv@tisserie	artisanale	Petit-dv@jeuner	Paprika	Synth	@tique	E163,11.65	Algue	Biologique	ColorBio	Maroc	Non certifi		
23	22	3	54	50	52	51	19	16	35	0,81	0,176	08	2023-01-03	T1	Boisson	vi@gv@tale	Boisson	Paprika	Synth	@tique	E160c,9.19	Vâpice	Conventionnelle	GreenExtract	France	Non certifi		
24	23	54	35	27	64	20	96	0,0	2,0	60,57	2023-02-23	T1	Boisson	vi@gv@tale	Confiserie	Spiruline	Synth	@tique	E162,2.89	Lv@gume	Conventionnelle	ColorBio	Inde	ISO 22000				
25	24	53	35	81	33	14	76	7	26	0,93	0,867	48	2023-02-22	T1	Boisson	vi@gv@tale	Confiserie	Paprika	Naturel	E160c,11.31	Vâpice	Biologique	GreenExtract	France	Non certifi			
26	25	15	99	99	52	76	46	06	35	0,9	356	04	2023-01-15	T1	CV@rv@ales bio	Petit-dv@jeuner	Spiruline	Synth	@tique	E163,7.73	Vâpice	Conventionnelle	PureNature	Maroc	Non certifi			
Colorants Entretien Complet MDS																												

Figure 2: Base de données initiale (Fichier Excel)

5. Préparation de la source de données

❖ Objectif :

L'objectif de cette étape est d'**extraire et structurer les données brutes** nécessaires à la construction de notre entrepôt de données, à partir d'un **fichier CSV unique** contenant toutes les informations issues de notre modèle.

Avec mon binôme, nous avons choisi de **fusionner toutes les données en un seul fichier consolidé**, afin de **simplifier le processus ETL** dans Talend. Ce fichier contient :

- Les **clés de jointure** vers les différentes dimensions (produit, colorant, fournisseur, origine, temps)
- Les **mesures de la table des faits** : quantité vendue, montant de vente, score sanitaire et score environnemental
- Et toutes les **informations descriptives** des dimensions, comme :
 - le **type de colorant**, son **prix unitaire**, son **code E**
 - la **catégorie du produit alimentaire**
 - le **pays et la certification du fournisseur**
 - la **source** et la **nature** du colorant
 - la **date de vente**, avec le **jour**, le **mois**, le **trimestre** et l'**année**

Ce choix nous a permis de :

- **accélérer la lecture des données** dans Talend via un unique tFileInputDelimited
- effectuer les **transformations dans un seul flux**
- faciliter la création des **rapports dans Power BI**, sans nécessiter de jointures supplémentaires

Le fichier final, intitulé **Colorants_Entrepot_Complet.csv**, regroupe **100 lignes de ventes simulées**, et est conforme au modèle en étoile que nous avons défini.

Avant de passer à l'intégration dans Talend, **nous avons vérifié la qualité, la cohérence et la complétude de chaque fichier**. Cela inclut :

- Le contrôle des **types de données** (ex. : prix, quantités, dates, scores...)
- L'**absence de doublons** dans les dimensions
- La **correspondance entre les clés primaires et étrangères** pour faciliter les jointures

Avec mon binôme, nous avons également pris soin de **structurer ce fichier selon les principes d'un modèle en étoile**, en évitant toute redondance excessive et en respectant la normalisation :

- Les **dimensions** contiennent des **valeurs uniques** et descriptives
- La **table des faits** contient uniquement les **clés étrangères** vers les dimensions et les **mesures quantitatives**

Cette étape de préparation est essentielle, car elle garantit que **le processus ETL dans Talend** pourra s'exécuter sans erreur, et que **l'analyse OLAP** produira des résultats fiables et cohérents.

❖ Outil utilisé : Talend

Description Le processus d'intégration commence par l'**importation d'un fichier CSV unique** qui représente la **source initiale des données consolidées**. Dans Talend, nous avons utilisé un composant de lecture adapté pour **extraire les données ligne par ligne**, en respectant la structure définie lors de la phase de préparation.

Les données extraites sont ensuite **nettoyées et transformées** selon les besoins du **modèle multidimensionnel** (schéma en étoile). Cela inclut notamment :

- la **conversion de certains champs** (ex. : format numérique des scores, quantités, montants)
- la **génération automatique de champs dérivés** (comme `trimestre` ou `année` à partir du champ `mois`)
- l'**élimination de colonnes inutiles**
- et la **préparation des données à charger dans la base finale**



Extraction (Extraction des Données)

Description :

- Lire et charger les données brutes contenues dans le fichier `Colorants_Entrepot_Complet.csv`.

Composant utilisé dans Talend :

- **tFileInputDelimited**

Ce composant permet de :

- lire un **fichier CSV avec séparateur**, ligne par ligne
- définir la **structure des colonnes** (nom, type, format)
- **transmettre les données** vers les composants suivants du flux

Étapes détaillées :

1. On crée un nouveau job (**EDD_Colorants**)




Figure 3: new job

1. Création du schéma dans **Metadata > File Delimited**
2. Spécification du **chemin du fichier**, du **délimiteur** (virgule), et du **type UTF-8**
3. Vérification de la **structure des colonnes** (100 lignes, avec types corrects : int, float, string, Date type date et modèle dd/MM/yyyy au lieu de dd-MM-yyyy.)
4. Intégration du fichier dans le **Job Talend principal**, via un `tFileInputDelimited`

Fichier - Étape 4 de 4

Ajouter un schéma au référentiel
Définissez le schéma

Nom: metadata

Commentaire:

Schéma

Cliquez pour mettre à jour la prévisualisation du schéma. [Détecter]

Description du schéma

Colonne	Clé	Type	Nullab	Modèle de date (Ctrl+Esp)	Longueur	Précision	Par défaut	Commentaire
Id_Temps	☒	Integer	☒		2	0		
Date	☐	Date	☒	"dd-MM-yyyy"	10	0		
Jour	☐	Integer	☒		2	0		
mois	☐	Integer	☒		1	0		
trimestre	☐	String	☒		2	0		
annee	☐	Integer	☒		4	0		

< Back Next > Cancel Finish

Figure 4: Etape 4 de la création de fichier CSV

2. Ajoute un composant `tFileInputExcel` dans Talend.

3. Relie ce composant à un composant **tLogRow** (pour visualiser les données extraites).




Figure 5: composant tFileInputExcel configuré

Transformation (Organisation) :

Description :

Cette étape consiste à **préparer, organiser et transformer les données extraites**, afin qu'elles soient **conformes au modèle multidimensionnel** défini précédemment (schéma en étoile). Elle permet de **nettoyer, formater et enrichir** les données avant leur chargement dans l'entrepôt de données.

Composant tMap de Talend

Ce composant est au cœur de la transformation. Il offre une interface visuelle pour :

- sélectionner les colonnes utiles
- renommer ou reformater les champs
- créer de nouveaux champs calculés
- filtrer les données, si nécessaire

Étapes détaillées :

1. Ajoute un composant **tMap** et connecte-le à **tFileInputExcel**.




Figure 6: Connexion tFileInputExcel → tMap pour la transformation

2. Crée des colonnes de sortie pour les dimensions.




Figure 7: Configuration de tMap

3. Ajoute des transformations :

- **Mapping des colonnes** : Nous avons procédé à une **correspondance explicite entre les colonnes du fichier source et les colonnes attendues en sortie** dans le schéma cible. Cela garantit une structure cohérente des données et facilite leur insertion dans les tables de l'entrepôt de données, conformément au modèle en étoile.
- **Extraction et séparation des composantes de la date** : À partir d'un champ contenant une **date complète** (ex. : "23/12/2024"), nous avons utilisé la fonction `TalendDate.getPartOfDate()` pour extraire automatiquement :

le **jour** : 23

le **mois** : 12

l'**année** : 2024

Ces composantes ont ensuite été utilisées pour alimenter la **dimension temporelle (Dim_Temps)** et permettre des **analyses détaillées par période** (mensuelle, annuelle, etc.) dans les tableaux de bord ou les cubes OLAP.

Dim_Temps	
Expression	Column
row1.id_Temps	id_Temps
TalendDate.formatDate("dd", row1.l	Jour
TalendDate.formatDate("MM", row1	mois
row1.trimestre	trimestre
TalendDate.formatDate("yyyy", row	annee

Figure 8: Extraction des composants de la date avec `TalendDate.formatDate`

4. Phase 2 : Création de la Base de Données Intermédiaire

Objectif : □ Centraliser les données extraites dans une base intermédiaire afin de structurer les dimensions nécessaires à la construction du Data Warehouse.

- **Outil utilisé :** Xampp Server (serveur MySQL).
- **Description de l'étape :** Cette base permet de stocker et organiser les données extraites en tables distinctes, **chacune correspondant à une dimension spécifique de l'entrepôt de données**. Les dimensions nécessaires sont : **Produit, Colorant, Temps, Origine, Fournisseur**. Ce processus inclut des opérations de **nettoyage**, de **suppression de doublons**, et de **conversion de types de données** (par exemple, conversion des dates au bon format). Ces transformations garantissent une structure claire avant le chargement final vers le **Data Warehouse**.

Étapes détaillées :

1. Crée une nouvelle Base de données MySQL vide dans phpMyAdmin (WampServer) :




Figure 9 :Création de la Base de Données Intermédiaire

2. Crée une nouvelle connexion base de données MySQL en Talend, en indiquant l'identifiant, le port, le serveur utilisé (localhost) et le nom de base de données qu'on a créé ;




Figure 10: Création d'une connexion MySQL dans Talend (bdd_etl)

- **Vérification de la connexion avec la Base de données ;**




Figure 11: Connexion établie (bdd_etl)

3. Ajoute des composants **tDBOutput**,




Figure 12: Ajout des composants **tDBOutput pour la gestion des tables**

4. Relie chaque composant **tDBOutput** avec **tMap** et on spécifier pour chaque table une **tDBOutput**




Figure 13: Connexion des composants tDBOutput avec tMap (1)




Figure 14: Connexion des composants tDBOutput avec tMap (2)

5. Pour chaque composant **tDBOutput**, on spécifie le nom de la table correspondante, puis on choisit l'option "Supprimer la table si elle existe et la recréer" comme action sur la table, afin de garantir sa création correcte.




Figure 15: Configuration des actions tDBOutput pour la création des tables

6. On exécute le job,




Figure 16: exécution de job pour le chargement dans bdd_etl

7. On vérifie que le chargement des tables a été bien effectué dans notre base de données MySQL,

Table	Action	Lignes	Type	Interclassement	Taille	Pe
☐ Dim_Colorant	★ Parcourir Structure Rechercher Insérer Vider Supprimer	64	InnoDB	utf8mb4_general_ci	16,0 kio	
☐ Dim_Fournisseur	★ Parcourir Structure Rechercher Insérer Vider Supprimer	64	InnoDB	utf8mb4_general_ci	16,0 kio	
☐ Dim_Origine	★ Parcourir Structure Rechercher Insérer Vider Supprimer	64	InnoDB	utf8mb4_general_ci	16,0 kio	
☐ Dim_Produit	★ Parcourir Structure Rechercher Insérer Vider Supprimer	60	InnoDB	utf8mb4_general_ci	16,0 kio	
☐ Dim_Temps	★ Parcourir Structure Rechercher Insérer Vider Supprimer	60	InnoDB	utf8mb4_general_ci	16,0 kio	
5 tables	Somme	312	InnoDB	utf8mb4_general_ci	80,0 kio	0

☐ Tout cocher
 Avec la sélection :

Figure 17: Vérification du chargement des tables dans la base de données MySQL

7. Création de l'entrepôt de données :

❖ **Objectif** : Construire les dimensions de l'entrepôt de données à partir des informations stockées dans la base intermédiaire bdd_etl, puis les intégrer dans la base finale nommée EntrepotDeDonnees


❖ **Outils utilisés** : Talend, MySQL

❖ **Description de l'étape** :

1. **Extraction des données depuis la base intermédiaire (bdd_etl)** : Les différentes dimensions du projet (Temps, Produit, Colorant, Origine, Fournisseur) ont été extraites de la base bdd_etl à l'aide de Talend. Chaque table représente une dimension essentielle à l'analyse des ventes de colorants dans le modèle en étoile.
2. **Transformation via le composant tMap** : Les données ont été transformées et nettoyées avec le composant *tMap*. Cela inclut l'uniformisation des formats de date, la conversion des types de données (par exemple : de texte à date), et l'adaptation des champs pour respecter le schéma de l'entrepôt de données.
3. **Chargement dans la base datawarehouse** : Les données transformées ont été insérées dans la base finale datawarehouse, dans des tables de dimensions distinctes : Dim_Temps, Dim_Produit, Dim_Colorant, Dim_Origine et Dim_Fournisseur. Ces tables structurées facilitent les futures analyses multidimensionnelles, comme le suivi des ventes, l'impact environnemental ou encore la traçabilité des fournisseurs.

Étapes détaillées :

1. Crée une nouvelle Base de données MySQL vide dans phpMyAdmin (XamppServer) sous le nom **EntrepotDeDonnees**.



1. *Figure 18: création de la BDD vide EntrepotDeDonnees.*

2. On crée un nouveau job (**EntrepotDeDonnees**)




Figure 19: création de job DataWarehouse

3. Crée une nouvelle connexion base de données MySQL en Talend dans les métadonnées, en indiquant l'identifiant, le port, le serveur utilisé (localhost) et le nom de base de données qu'on a créé (EntrepotDeDonnees), et on vérifie la connexion.




Figure 20: création de connexion avec la bdd EntrepotDeDonnees

4. On récupère le schéma de la base de données bdd_etl dans Talend, et on vérifie la connexion.




Figure 21: récupération de schéma




Figure 22: la sélection des tables pour créer le schéma

5. Ajoute des composants **tDBInput (MySQL)** pour chaque table qui représente une dimensions de notre EntrepotDeDonnees depuis les schémas des tables récupérées dans la métadonnée BDD_ETL dans le Workspace de notre job,




Figure 23: l'ajout des composants tDBInput de BDD_ETL

6. Ajoute des composants **tMap** et connecte-les à chaque composant **tDBInput**.




Figure 24: Ajout et relie des composants tMap avec tDBInput

7. Configuration du **tMap** pour les dimensions dans l'entrepot de données : Le composant **tMap** a été utilisé pour mapper les colonnes de chaque table source (provenant de la base intermédiaire bdd_etl) vers les tables correspondantes dans le Data Warehouse (datawarehouse).




Figure 25 : Configuration du tMap pour le Mapping de Dimension Anime




Figure 26: Configuration du tMap pour le Mapping de Dimension Date




Figure 27: Configuration du tMap pour le Mapping de Dimension Source




Figure 28: Configuration du tMap pour le Mapping de Dimension Source




Figure 29: Configuration du tMap pour le Mapping de Dimension Studio

8. Ajoute des composants **tDBOutput** de la base de données datawarehouse.




Figure 30: Ajout des Composants *tDBObject* pour la Base de Données Data Warehouse

9. Relie chaque composant **tDBObject** avec son **tMap** approprié et on spécifier pour chaque table une **tDBObject**




Figure 31: association *tDBObject* et *tMap* pour chaque table

10. Pour chaque composant **tDBObject** on ajoute le nom associé à la table et on sélectionne « Supprimer la table si elle existe et la créer » comme une action sur la table pour confirmer que la table sera bien créée.




Figure 32: Configuration de tDBOutput : Nom et action

11. On exécute le job,



Figure 33: exécution de job EntrepotDeDonnees

12. On vérifie que le chargement des tables a été bien effectué dans notre base de données MySQL,




Figure 34: vérification de chargement des dimensions dans la bdd EntrepotDeDonnees

❖ Structure des dimensions créées :

- **Dim_Produit** : contient les informations sur chaque produit utilisant des colorants (nom, catégorie, etc.).
- **Dim_Temps** : représente les détails temporels de chaque vente (date, jour, mois, trimestre, année).
- **Dim_Colorant** : regroupe les informations sur les colorants (nom, type, code E, prix unitaire).
- **Dim_Origine** : indique l'origine des matières premières (source et nature).
- **Dim_Fournisseur** : détaille les fournisseurs (nom, pays, certification).

Création de la table de faits Faits_Ventes_Colorants :

Objectif : Créer une table de faits centralisant les mesures issues des ventes (quantité vendue, montant, score santé, score environnemental) en lien avec les dimensions, pour structurer l'analyse dans l'entrepôt de données.

Outils utilisés : Talend Open Studio (composant *tMap*), MySQL

Description de l'étape :

1. Récupération des données nécessaires :

Les **clés primaires** des dimensions (id_produit, id_colorant, id_Temps, id_origine, id_Fournisseur) sont extraites de la base datawarehouse.

Les **mesures** (quantité_kg, montant_vente, score_sante, score_env) proviennent du fichier source Excel simulant les ventes.

2. Configuration du composant *tMap* dans Talend :

Dans Talend, les clés des dimensions ont été associées aux colonnes du fichier source en s'appuyant sur des règles de correspondance (ex. : nom du colorant, date de vente, nom du fournisseur).

Cela permet de générer les **clés étrangères** nécessaires pour relier chaque ligne de vente aux dimensions appropriées.

3. Création et chargement de la table de faits :

La table Faits_Ventes_Colorants a été construite avec :

Les clés étrangères des dimensions (id_Temps, id_produit, id_colorant, id_origine, id_Fournisseur)

Les mesures de vente (quantité_kg, montant_vente, score_sante, score_env)

La table a ensuite été chargée dans la base datawarehouse pour être utilisée dans les analyses futures (ex. : tendances de vente, impact des fournisseurs, etc.).

Étapes détaillées :

1. On crée un nouveau job (**TableDeFaits**)




Figure 35: Création de nouveau job "TableDeFaits"

2. On récupère le schéma de la base de données EntrepotDeDonnees dans Talend,




Figure 36: Récupération de schéma de la base de données EntrepotDeDonnees

Sélectionner le schéma à créer

Nom du filtre :

Nom	Type	Nombre de colonnes	Statut de la création
☒ EntrepotDeDonnees	CATALOG		
☒ Dim_Colorant	TABLE	5	Succès
☒ Dim_Fournisseur	TABLE	4	Succès
☒ Dim_Origine	TABLE	3	Succès
☒ Dim_Produit	TABLE	3	Succès
☒ Dim_Temps	TABLE	5	Succès

Tout sélectionner Ne rien sélectionner Vérifier la connexion

Figure 37: Sélection des tables pour créer schéma

5. On ajoute le composant **tFileInputDelimited** (de notre fichier CSV de base) et des composants **tDBInput(MySQL)** pour chaque table qui représente une dimensions de notre entrepot de donnes depuis les schémas des tables récupérées dans la métadonnée depuis la bdd EntrepotDeDonnees dans le Workspace de notre job,




Figure 38: Ajout de tFileInputExcel et tDBInput pour les dimensions

3. Ajoute un composant **tMap** et connecte-le avec le composant **tFileInputDelimited** et les composants **tDBInput (MySQL)** .




Figure 39: Ajout de tMap et connexion avec tFileInputDelimited et tDBInput

4. Configuration du composant **tMap** :

- Connexion **des dimensions et des mesures** :

- Dans le composant **tMap**, on a relié les **clés primaires des dimensions** (issues des tables de dimensions de **EntrepotDeDonnes**) aux colonnes correspondantes du fichier Excel initial.
- Cela permet de créer des relations logiques entre les dimensions et les mesures.




Figure 40: Connexion des dimensions et des mesures

- **Génération des clés étrangères :**

- Des **clés violettes** (clés étrangères) ont été automatiquement générées dans le **tMap** pour relier les dimensions à la table de faits.




Figure 41: Génération des clés étrangères

- Génération de la table de faits :
 - Une **table de faits** a été construite en combinant :
 - Les **clés étrangères** issues des **dimensions** :
id_produit, id_colorant, id_Temps, id_origine, id_Fournisseur.
 - Les **mesures** extraites du **fichier CSV source** :
quantité_kg, montant_vente, score_sante, score_env.




Figure 42: Génération de la table de faits dans tMap

13. On ajoute un composant **tDBObject** de la base de données EntrepotDeDonnees

14. Relie le composant **tDBObject** avec le composant **tMap**




Figure 43: association de tMap avec le composant tDBObject

15. On ajoute le nom associé à la table de faits et on sélectionne « Supprimer la table si elle existe et la créer » comme une action sur la table pour confirmer que la table sera bien créée.

16. On exécute le job,




Figure 44: exécution de job TableDeFaits

17. On vérifie que le chargement de la table de faits a été bien effectué

Table	Action	Lignes	Type	Interclassement	Taille
Dim_Colorant	Parcourir Structure Rechercher Insérer Vider Supprimer	64	InnoDB	utf8mb4_general_ci	16,0 ki
Dim_Fournisseur	Parcourir Structure Rechercher Insérer Vider Supprimer	64	InnoDB	utf8mb4_general_ci	16,0 ki
Dim_Origine	Parcourir Structure Rechercher Insérer Vider Supprimer	64	InnoDB	utf8mb4_general_ci	16,0 ki
Dim_Produit	Parcourir Structure Rechercher Insérer Vider Supprimer	60	InnoDB	utf8mb4_general_ci	16,0 ki
Dim_Temps	Parcourir Structure Rechercher Insérer Vider Supprimer	60	InnoDB	utf8mb4_general_ci	16,0 ki
Faits_Vente_Colorants	Parcourir Structure Rechercher Insérer Vider Supprimer	412	InnoDB	utf8mb4_general_ci	96,0 ki
6 tables	Somme	412			96,0 ki

Figure 45: Vérification de chargement de la table de faits dans l'entrepôt de données

8. Conclusion :

Dans ce chapitre, nous avons mis en œuvre la méthode de conception dimensionnelle de **Kimball** afin de bâtir un **entrepôt de données (Data Warehouse)** centré sur l'analyse des ventes de colorants. Cette démarche a été guidée par les besoins décisionnels, en adoptant un **modèle en étoile** articulé autour d'une **table de faits** et de plusieurs **tables de dimensions**.

Nous avons commencé par **extraire et nettoyer les données brutes** issues de fichiers CSV. Ces données ont ensuite été **stockées dans une base intermédiaire** pour faciliter les opérations de transformation. Grâce à l'outil **Talend Open Studio**, chaque dimension (produit, colorant, fournisseur, origine, temps) a été construite séparément, puis les mesures de vente (quantité, montant, scores) ont été intégrées dans une **table de faits** consolidée.

Le **Data Warehouse final** représente une base solide et structurée pour des **analyses multidimensionnelles**, permettant d'observer les ventes sous différents axes (temporel, produit, fournisseur, etc.). Cette fondation va maintenant permettre d'enrichir l'analyse grâce à la **modélisation OLAP**, notamment par la construction de **cubes d'analyse** qui faciliteront l'exploration interactive des données, l'identification des tendances, et la prise de décision stratégique.

Chapitre 3 : Création de cube OLAP

1. Introduction :

Dans ce chapitre, nous exploitons le **Data Warehouse** construit précédemment pour élaborer un **cube OLAP** à l'aide de l'outil **Pentaho Schema Workbench**. Cette phase a pour objectif de structurer les données de manière multidimensionnelle afin de faciliter des **analyses dynamiques et interactives**.

Le **cube OLAP** repose sur la table de faits et les tables de dimensions, permettant l'exploration des données selon plusieurs axes d'analyse (dimensions telles que le **temps**, le **fournisseur**, ou le **type de colorant**, et mesures telles que le **nombre de ventes**, le **montant total**, ou encore la **note moyenne** des produits).

2. Data Mart :

Un **Data Mart** représente un sous-ensemble thématique du Data Warehouse, spécialement conçu pour répondre à des besoins analytiques précis. Dans le contexte de notre projet, il est centré sur l'analyse des ventes de **colorants industriels**, offrant une vue synthétique et ciblée des données collectées.

Le Data Mart regroupe les informations extraites, transformées et chargées au cours des étapes précédentes. Il est structuré selon un **modèle en étoile**, intégrant une table de faits centrale et plusieurs **dimensions analytiques** :

Dimensions principales :

- **Produit / Colorant** : Informations sur chaque produit vendu (nom, type, usage, etc.).
- **Date** : Granularité temporelle pour l'analyse (jour, mois, année).
- **Fournisseur** : Données sur les entreprises fournisseurs (nom, pays, réputation).
- **Origine** : Catégorisation par source ou provenance des matières premières.
- **Score / Évaluation** : Données qualitatives ou quantitatives évaluant les performances ou la qualité du colorant.

Les **mesures quantitatives**, issues de la table de faits, comprennent :


- **Nombre de ventes**
- **Montant total**
- **Score d'évaluation (%)**
- **Note moyenne**

Ce Data Mart constitue la base de la modélisation du cube OLAP, assurant une navigation fluide dans les données pour produire des indicateurs décisionnels fiables.

Définition de Data Marts analytiques définis dans le projet :

1. **Popularité par Colorant :**
 - Classe les produits selon leur nombre de ventes ou leur note moyenne pour identifier les plus performants.
2. **Ventes par Période :**
 - Analyse les volumes de vente par mois ou par année pour détecter les saisons les plus actives.
3. **Performances Fournisseur**
 - Évalue les performances commerciales des différents fournisseurs en lien avec les quantités vendues et les évaluations.
4. **Analyse par Type de Colorant**
 - Étudie quels types de colorants (naturels, synthétiques, alimentaires, textiles, etc.) dominent les ventes.
5. **Impact de l'Origine sur les Ventes**
 - Compare les origines (locale, importée, naturelle, chimique) en fonction de leur impact sur la popularité et le volume des ventes.
6. **Évolution Annuelle des Ventes**
 - Retracer l'évolution des ventes et de la satisfaction client au fil des années.
7. **Répartition Géographique des Fournisseurs**
 - Analyse les régions ou pays d'origine des fournisseurs en relation avec leurs performances commerciales.
8. **Relation entre Usage et Quantité**
 - Examine si les types d'usage des colorants influencent les quantités vendues.

3. Création du Cube OLAP :



Technologie utilisée :

Pentaho Schema Workbench

Figure 46: interface de Pentaho Schema Workbench

Création du cube :

Étape 1 : Ouvrir Pentaho Schema Workbench

1. Nous lançons Pentaho Schema Workbench sur notre machine.
2. Une fois ouvert, nous créons un nouveau projet en sélectionnant File → New → Schema.




Figure 47: Création d'un nouveau projet

Étape 2 : Définir la connexion à la base de données

1. Nous définissons d'abord la connexion entre Pentaho et notre base de données SQL en suivant ces étapes :
 - Nous allons dans le menu Options → Connections.
 - Nous ajoutons une nouvelle connexion :
 - Nom : cube.
 - Type : MySQL.
 - Hôte : localhost.
 - Nom de la base : le data warehouse que nous avons créé dans les étapes précédentes (EntrepotDeDonnees).
 - Identifiant et mot de passe : Les identifiants de connexion configurés dans MySQL.




Figure 48: Définition de la connexion avec la bdd MySQL

- Nous testons la connexion pour s'assurer que tout fonctionne.





Figure 49: le test de la connectivité de la bdd

Étape 3 : Créer un Schema

1. Dans notre projet, nous ajoutons un nouveau Schema :
 - Nous attribuons un nom significatif : cube_olap.
 - Nous associons le Schéma à la connexion que nous venons de créer (cube).



Attribute	
name	cube_olap
description	
measuresCaption	
defaultRole	

Figure 50: création de nouveau schéma

Étape 4 : Définir les dimensions et la table de faits :

1. Nous créons un nouveau cube,




Figure 51: l'ajout d'un cube

- Nous attribuons un nom significatif : **cube_olap**.




Figure 52: Nomination de cube

2. Nous définissons la table des faits :
 - Nom de la table des faits : faits_vente_colorants




Figure 53: Ajout et définition de la table de faits

3. Nous créons les dimensions en nous basant sur notre modèle en étoile :




Figure 54: ajout des dimensions




Figure 54: dimensions ajoutées

- On définit une nouvelle hiérarchie pour introduire les attributs de la dimension :




Figure 55: ajout d'une hiérarchie pour les dimension ex(colorants)

- On remplit les champs d'informations sur la dimension (hiérarchie) : le nom, la clé primaire de la dimension,




Figure 56: remplissage des infos sur la hiérarchie dim_origine

- On ajoute plusieurs niveaux pour introduire les attributs de la dimension, chaque niveau présente un attribut,




Figure 57: l'ajout d'un niveau pour une attribut

- Pour chaque niveau on remplit les champs appropriés le nom d'attribut, le nom de la table (dimension), la colonne, le nom de la colonne, le type de l'attribut et on cocher sur la case visible.




Figure 58: remplissage des métadonnées de l'attribut id_colorant

Chaque **table dimensionnelle** du projet a été soigneusement enrichie afin d'assurer une exploitation optimale dans le cube OLAP. Cela inclut l'ajout de **métadonnées** précises (descriptions, types de données, formats) pour chaque attribut, permettant ainsi une meilleure compréhension et documentation du contenu des dimensions.

Des **hiérarchies** ont été définies pour faciliter l'analyse à différents niveaux d'agrégation. Par exemple, dans la **dimension Date**, une hiérarchie temporelle a été construite suivant le schéma classique : **Année > Trimestre > Mois > Jour**, ce qui permet d'analyser les ventes de colorants à différents degrés de granularité. D'autres hiérarchies ont également été créées, facilitant ainsi les analyses géographiques ou techniques.

Parallèlement, la **table de faits** a été définie comme le centre du modèle en étoile. Elle regroupe les **mesures quantitatives** pertinentes pour l'analyse, telles que le **nombre d'unités vendues(quantité)**, le **montant total de vente**, le **score santé** et le **score environnemental**. Ces mesures sont reliées aux **clés étrangères** issues des dimensions correspondantes (Fournisseur, Colorant, Date, Produit, Origine), assurant l'intégrité des relations dans le modèle.

Ce **modèle multidimensionnel**, construit à l'aide de Pentaho Schema Workbench, permet ainsi une **exploration fluide et interactive** des données de ventes de colorants. Les utilisateurs peuvent naviguer parmi différentes **perspectives analytiques**, comme visualiser les performances par fournisseur, suivre les tendances saisonnières ou annuelles, comparer les ventes par type de colorant, ou encore analyser l'impact environnemental selon l'origine des produits. Cette structure constitue une **base solide pour l'analyse décisionnelle**, en fournissant des indicateurs fiables et bien structurés pour appuyer les stratégies commerciales et écologiques autour des colorants.




Figure 59: l'ajout d'une mesure




Figure 60: la mesure quantite_kg bien définie

Une fois la modélisation multidimensionnelle terminée, comprenant la définition des dimensions, des hiérarchies, des mesures et de la table de faits, l'étape finale consiste à **générer et sauvegarder le schéma en fichier XML**. À l'aide de **Pentaho Schema Workbench**, le schéma OLAP est exporté sous forme de fichier .xml, qui sert de **descripteur officiel du cube OLAP**. Ce fichier contient la structure complète du modèle, incluant les métadonnées, les relations entre les dimensions et la table de faits, ainsi que les hiérarchies définies.

Le fichier XML est enregistré localement puis importé dans le serveur BI, où il devient exploitable pour les utilisateurs finaux souhaitant effectuer des analyses avancées sur les données de ventes de colorants.

Ainsi, cette dernière étape marque la **finalisation du processus de conception du cube**, en rendant le modèle opérationnel et prêt à être utilisé dans un environnement décisionnel professionnel.

5. Conclusion

Dans ce chapitre, nous avons conçu un cube OLAP en nous appuyant sur le Data Warehouse construit précédemment, à l'aide de **Pentaho Schema Workbench**. Ce cube multidimensionnel relie les différentes **dimensions** du projet (Fournisseur, Date, Type de Colorant, Origine, Région) à la **table de faits des ventes**, contenant les **mesures** telles que la quantité vendue, le prix unitaire et le chiffre d'affaires.

Grâce à cette structure, il est désormais possible d'effectuer des **analyses décisionnelles avancées** en explorant les ventes de colorants selon plusieurs angles : par période, par fournisseur, par zone géographique ou encore par type de produit. Ce cube constitue ainsi un outil puissant pour appuyer les prises de décisions stratégiques, en offrant une **vision synthétique et dynamique** des données

Chapitre 4 : Analyse et Visualisation des Résultats

1. Introduction :

Ce chapitre est consacré à l'analyse et à la visualisation des résultats extraits du **Data Warehouse développé autour des ventes de colorants**. En utilisant **Microsoft Power BI**, nous avons conçu des tableaux de bord interactifs permettant de mettre en évidence des indicateurs clés tels que la **quantité vendue**, le **chiffre d'affaires**, ou encore les **performances par fournisseur, région, origine ou période**.

L'objectif est d'offrir aux décideurs des **informations claires et exploitables** pour orienter les stratégies commerciales, optimiser la gestion des stocks, ou encore identifier les opportunités de développement. Les **datamarts préalablement définis** servent ici de base pour les différentes analyses, couvrant des aspects tels que la rentabilité par type de colorant, la saisonnalité des ventes, ou encore la contribution des fournisseurs au chiffre d'affaires global.

Chaque visualisation est accompagnée d'interprétations pertinentes afin de **dégager des insights utiles** à la prise de décision.

1. Connexion de Power BI à la Base de Données MySQL "EntrepotDeDonnees"

2. Ouvrir Power BI Desktop

- Lancer Power BI Desktop pour créer un nouveau rapport.

3. Se connecter à MySQL

- Cliquer sur Obtenir des données dans le ruban.
- Sélectionner MySQL Database comme source de données.




Figure 61: obtention des données

4. Entrer les informations de connexion

- Dans la fenêtre qui apparaît, entrer localhost comme serveur.
- Entrer EntrepotDeDonnees comme nom de la base de données.

Figure 62: l'insertion des infos de connexion avec la bdd

- Choisir le mode d'authentification, puis entrer le nom d'utilisateur et le mot de passe.




Figure 63: l'insertion des infos de connexion avec la bdd (2)

5. Sélectionner les données

- Une fois connecté, Power BI affiche un aperçu des tables (dimensions) disponibles dans la base "EntrepotDeDonnees".
 - Sélectionner les données à importer pour les analyser.




Figure 64: chargement de la dimension Dim_colorant

Création de Visualisation




Figure 65: Diagramme en barres groupées : Corrélation entre les ventes et les scores santé des colorants

Présentation Générale :

Ce **diagramme en barres groupées** propose une **analyse croisée** entre les **volumes de vente** (quantité) et les **scores santé des colorants alimentaires**, répartis par **année** et par **catégorie**.

Principales Observations :

Pics de Performance (2021 & 2023) :

Les années **2021** et **2023** enregistrent des **volumes de vente élevés** (jusqu'à 500 unités).

Ces ventes sont accompagnées de **scores santé élevés** (entre 100 et 150), en particulier pour les colorants **d'origine végétale** (*algues, légumes*), soulignant leur **attrait commercial** et leur **bon profil sanitaire**.

Variabilité Marquée :

Hétérogénéité dans les performances selon les colorants :

Interprétation :

Les **colorants naturels** semblent offrir une **stabilité entre performance commerciale et qualité sanitaire**.

Les **colorants synthétiques**, en revanche, présentent des **fluctuations plus importantes**, tant en termes de ventes que de scores santé.

La **baisse généralisée des scores en 2020**, malgré des ventes toujours soutenues, pourrait suggérer un **relâchement des normes de qualité** ou un **changement dans les pratiques de production**.




Figure 66: Diagramme en barres empilées : Évolution des scores santé des colorants selon la source et l'année

Présentation :

Ce graphique illustre la **répartition des scores santé** de divers **colorants alimentaires**, classés par **source d'origine** et par **année**.

Analyse :

On remarque une **forte dominance** des **colorants d'origine végétale** (notamment **algues** et **légumes**), qui obtiennent de manière constante les **meilleurs scores**, ce qui reflète probablement un **profil sanitaire plus favorable**.

Les **années 2006 et 2008** présentent une **distribution complète** des données, avec des **scores progressifs allant de 0 à 150**.

En revanche, les **années 2007 et 2009** semblent **partiellement renseignées**, ce qui **limite la fiabilité** de leur interprétation.

Certains colorants, affichent des **scores nuls**, ce qui pourrait révéler des **problèmes de qualité**

Cette visualisation souligne **l'influence notable de la source d'origine** sur la **qualité sanitaire** des colorants.




Figure 70: graphique en secteurs – Répartition Ventes / Scores Qualité par nom de Colorants

Observation :

Ce **graphique circulaire** représente la **répartition des ventes** et des **scores qualité** (environnementaux et sanitaires) selon les **différentes catégories de colorants alimentaires**. Les **colorants synthétiques** occupent une **part de marché majoritaire**, tandis que les **colorants naturels**, bien que **moins présents en volume**, se distinguent par des **performances qualitatives nettement supérieures**.

La visualisation met en évidence les **proportions relatives** de chaque type de colorant ainsi que leur **niveau de performance**, offrant ainsi une **vue d'ensemble claire et synthétique** des tendances du secteur.




Figure 67: graphique en anneau Distribution des Produits et des Scores (Environnement & Santé) selon le nom de Colorant




Figure 68: distribution des produits par source et quantité vendue par trimestre




Figure 69: évolution des scores santé selon la nature au fil des ans




Figure 68: distribution des produits par source et quantité vendue par trimestre




Figure 69: évolution des scores santé selon la nature au fil des ans

4. Conclusion :

L'analyse et la visualisation des données ont permis de faire émerger des **tendances claires** et des **insights pertinents** sur la **performance commerciale et sanitaire des colorants alimentaires**, en croisant plusieurs dimensions telles que la **catégorie**, la **source**, la **période** et le **type de colorant**. Grâce à **Power BI**, ces résultats sont présentés de manière **interactive et lisible**, facilitant ainsi la **prise de décision** pour les acteurs du secteur.

Ces analyses mettent en évidence le **rôle stratégique des données** dans l'**optimisation des choix liés aux produits**, la **gestion des risques sanitaires**, et l'**amélioration continue des pratiques commerciales**. Elles soulignent l'intérêt d'une **approche data-driven** pour mieux comprendre les dynamiques du marché et guider les orientations futures dans l'**industrie des additifs alimentaires**.

Infrastructure Technique et Environnement de Développement :

❖ **Talend Open Studio**

Type : Outil ETL (Extract – Transform – Load)

Description :

Talend est une solution open-source puissante utilisée pour **extraire, transformer et charger** des données depuis différentes sources vers un entrepôt de données.

Dans notre projet, Talend a permis de :

Nettoyer et harmoniser les données (ex. : correction des libellés incohérents).

Gérer les flux de données entre les fichiers sources et la base de données.

Orchestrer des traitements automatiques avec des jobs ETL visuels.

❖ **XAMPP**

Type : Environnement de serveur local (Apache, MySQL, PHP, Perl)



Description :

XAMPP est un **package serveur** tout-en-un permettant de simuler un **environnement web local** pour héberger et gérer une **base de données MySQL**.

Dans notre projet, XAMPP a été utilisé pour :

Créer et gérer la **base de données centrale** (entreposage des données transformées).

Tester les connexions entre les outils ETL (Talend/Pentaho) et le SGBD MySQL.

Offrir un environnement stable et local pour le développement et les tests.

❖ **Pentaho Schema Workbench**

Type : Outil de modélisation OLAP (schemas multidimensionnels)

Description :

Pentaho Schema Workbench est un outil de la suite Pentaho permettant de **concevoir des schémas OLAP** (Online Analytical Processing) pour l'analyse multidimensionnelle des données.

Il est utilisé pour créer des **modèles en étoile ou en flocon**, en définissant :

Cubes analytiques regroupant les faits (mesures comme ventes, scores, quantités).

Dimensions (ex. : Fournisseur, Date, Type de Colorant, Région).

Hiérarchies et niveaux d'analyse (ex. : Année > Mois > Jour).

❖ **Power BI**

Type : Outil de Business Intelligence et de Datavisualisation

Description :

Power BI est une solution développée par Microsoft permettant de créer des **dashboards interactifs** et des **rapports dynamiques** à partir de données structurées.



Dans le cadre de notre projet :

Power BI a permis de **visualiser les performances des colorants** (ventes, scores qualité, tendances).

Les filtres, segments et graphiques interactifs ont facilité l'analyse exploratoire.

Les rapports ont servi de support décisionnel clair pour les parties prenantes.

Conclusion générale :

Ce projet a permis de créer un **data warehouse efficace** pour l'analyse des données liées aux colorants alimentaires, en utilisant une combinaison d'outils spécialisés.

- **Talend** a été utilisé pour l'**ETL** (extraction, transformation, chargement), facilitant le traitement et la préparation des données en amont.
- **XAMPP** a servi de **plateforme de gestion des bases de données**, offrant un environnement local stable pour le stockage des informations.
- **Pentaho Schema Workbench** a permis de structurer les données dans un modèle **multidimensionnel OLAP**, en créant des cubes permettant des analyses détaillées selon divers axes (ex. : fournisseur, type de colorant, performance sanitaire).
- **Power BI** a facilité la **visualisation interactive** des résultats, offrant des rapports et graphiques dynamiques pour une présentation claire et compréhensible des données.

Grâce à cette architecture, les données brutes ont été transformées en **informations utiles**, permettant d'analyser la **répartition des ventes** et les **scores qualité** des colorants, tout en optimisant les décisions liées à la production et au marketing. Les analyses ont mis en évidence les performances des **colorants synthétiques** et **naturels**, ainsi que des tendances de **qualité sanitaire** et environnementale.

En résumé, ce projet illustre l'importance de l'**ETL**, de la **modélisation multidimensionnelle** et de la **visualisation BI** pour organiser, analyser et interpréter les données de manière efficace. Il montre comment un **data warehouse bien conçu** peut aider à prendre des décisions éclairées et à améliorer les **processus stratégiques** dans l'industrie des colorants alimentaires.

Références utilisées dans le projet

Outils utilisés :

1. **Talend Open Studio for Data Integration**
 - Outil d'ETL open source pour l'extraction, la transformation et le chargement de données.
 - <https://www.talend.com/products/data-integration/>
 2. **Power BI**
 - Outil de visualisation et d'analyse de données développé par Microsoft.
 - <https://powerbi.microsoft.com/>
 3. **PostgreSQL (ou MySQL selon ta base cible)**
 - Système de gestion de base de données relationnelle open source.
 - <https://www.postgresql.org/>
 4. **CSV Viewer (ou Excel/LibreOffice)**
 - Utilisé pour la visualisation manuelle des fichiers source.
 - <https://csvlint.io/> ou <https://www.libreoffice.org/>
-

Concepts théoriques :

5. **Modèle en étoile (Star Schema)**

Modélisation multidimensionnelle utilisée dans les entrepôts de données.

https://en.wikipedia.org/wiki/Star_schema
 6. **Processus ETL**

Extraction, Transformation, Chargement : étapes clés d'un projet décisionnel.

<https://datawarehouse4u.info/ETL-process.html>
 7. **OLAP (Online Analytical Processing)**

Méthode d'analyse multidimensionnelle dans les systèmes décisionnels.

https://en.wikipedia.org/wiki/Online_analytical_processing
 8. **Schéma en flocon de neige (Snowflake Schema) (si mentionné)**

https://en.wikipedia.org/wiki/Snowflake_schema
-

Données et simulations :

9. **Colorants alimentaires naturels – Exemples courants**

Informations sur les colorants naturels : curcuma, spiruline, hibiscus...

<https://www.efsa.europa.eu/en/topics/topic/food-colours>

https://fr.wikipedia.org/wiki/Liste_des_colorants
 10. **Code E des additifs alimentaires**

Normes européennes sur les colorants alimentaires (E100, E162, etc.)

https://fr.wikipedia.org/wiki/Additif_alimentaire
-

Recherches complémentaires (facultatives) :

11. **Impact environnemental des colorants naturels**
<https://www.ncbi.nlm.nih.gov/pmc/articles/PMC9367272/>
<https://www.frontiersin.org/articles/10.3389/fnut.2022.879665/full>
12. **Certification BIO / ISO 22000**
<https://www.iso.org/iso-22000-food-safety-management.html>
<https://agriculture.gouv.fr/le-label-agriculture-biologique-ab>